



浮点数的加减运算

浮点数加减运算步骤:

 $9.85211 \times 10^{12} + 9.96007 \times 10^{10}$

 $29.9517107 \times 10^{12}$

① 对阶

思考为什么 是小阶向大

① $9.85211 \times 10^{12} + 0.0996007 \times 10^{12}$

计算机内部,尾 数是定点小数

② 尾数加减

③ 规格化

③ 如果尾数加减出现类似 0.0099517×10¹² 时,需要"左规";如 果尾数加减出现类似 99.517107 × 10¹² 时, 需要"右规"

4 舍入

④ 若规定只能保留6位有效尾数,则 $9.9517107 \times 10^{12} \rightarrow 9.95171 \times 10^{12}$ (多余的直接砍掉)

或者, 9.9517107 × 10¹² → 9.95172 × 10¹² (若砍掉部分非0, 则入1) 或者,也可以采用四舍五入的原则,当舍弃位≥5时,高位入1

⑤ 判溢出

⑤ 若规定阶码不能超过两位,则运算后阶码超出范围,则溢出 如: $9.85211 \times 10^{99} + 9.96007 \times 10^{99} = 19.81218 \times 10^{99}$ 规格化并用四舍五入的原则保留6位尾数,得 1.98122× 10100 阶码超过两位,发生溢出(注:尾数溢出未必导致整体溢出,也许可 以通过③④两步来拯救)

王道考研/CSKAOYAN.COM

浮点数的加减运算

例:已知十进制数X=-5/256、Y=+59/1024,按机器补码浮点运算规则计算X-Y,结果 用二进制表示,浮点数格式如下:阶符取2位,阶码取3位,数符取2位,尾数取9位

用补码表示阶码和尾数

扩展: 11.011000000 双符号位补码: 11.011 双符号位补码: 11011

59D = 111011B, $1/1024 = 2^{-10} \rightarrow Y = +111011 \times 2^{-10} = +0.111011 \times 2^{-4} = +0.111011 \times 2^{-100}$

X: 11011,11.011000000 Y: 11100,00.111011000

浮点数加减运算步骤:

- 1. 对阶
- 2. 尾数加减
- 3. 规格化
- 4. 舍入
- 5. 判溢出

王道考研/CSKAOYAN.COM

浮点数的加减运算

例:已知十进制数X=-5/256、Y=+59/1024,按机器补码浮点运算规则计算X-Y,结果 用二进制表示,浮点数格式如下:阶符取2位,阶码取3位,数符取2位,尾数取9位

用补码表示阶码和尾数

0. 转换格式

5D = 101B, $1/256 = 2^{-8} \rightarrow X = -101 \times 2^{-8} = -0.101 \times 2^{-5} = -0.101 \times 2^{-101}$ 59D = 111011B, $1/1024 = 2^{-10} \rightarrow Y = +111011 \times 2^{-10} = +0.111011 \times 2^{-4} = +0.111011 \times 2^{-100}$ X: 11011,11.011000000 Y: 11100,00.111011000

浮点数加减运算步骤:

- 1. 对阶 使两个数的阶码相等,小阶向大阶看齐,尾数每右移一位,阶码加1
 - ① 求阶差: [\Delta E] 补=11011+00100=11111, 知\Delta E=-1
 - $X = -0.0101 \times 2^{-100}$ ②对阶: X: 11011,11.0110000000 → 11100,11. 101100000
- 2. 尾数加减
- 3. 规格化
- 4. 舍入
- 5. 判溢出

王道考研/CSKAOYAN.COM

浮点数的加减运算

例:已知十进制数X=-5/256、Y=+59/1024,按机器补码浮点运算规则计算X-Y,结果 用二进制表示,浮点数格式如下:阶符取2位,阶码取3位,数符取2位,尾数取9位

用补码表示阶码和尾数

0. 转换格式

5D = 101B, $1/256 = 2^{-8} \rightarrow X = -101 \times 2^{-8} = -0.101 \times 2^{-5} = -0.101 \times 2^{-101}$ 59D = 111011B, $1/1024 = 2^{-10} \rightarrow Y = +111011 \times 2^{-10} = +0.111011 \times 2^{-4} = +0.111011 \times 2^{-100}$ X: 11011,11.011000000 Y: 11100,00.111011000

浮点数加减运算步骤:

- 1. 对阶 使两个数的阶码相等,小阶向大阶看齐,尾数每右移一位,阶码加1
 - ① 求阶差: [\Delta E] 补=11011+00100=11111, 知\Delta E=-1
 - $X = -0.0101 \times 2^{-100}$ ② 对阶: X: 11011,11.0110000000 → 11100,11.101100000
- 11.101100000 X-Y 2. 尾数加减 -Y: 11100,11.000101000

= $(-0.0101 \times 2^{-100})$ - $(+0.111011 \times 2^{-100})$ + 11.000101000 X-Y: 11100, 10.110001000 $= (-0.0101-0.111011) \times 2^{-100}$

3. 规格化

10.110001000 $= -1.001111 \times 2^{-100}$

5. 判溢出

4. 舍入

王道考研/CSKAOYAN.COM

浮点数的加减运算

例:已知十进制数X=-5/256、Y=+59/1024,按机器补码浮点运算规则计算X-Y,结果 用二进制表示,浮点数格式如下:阶符取2位,阶码取3位,数符取2位,尾数取9位

用补码表示阶码和尾数

0. 转换格式

5D = 101B, $1/256 = 2^{-8} \rightarrow X = -101 \times 2^{-8} = -0.101 \times 2^{-5} = -0.101 \times 2^{-101}$ 59D = 111011B, $1/1024 = 2^{-10} \rightarrow Y = +111011 \times 2^{-10} = +0.111011 \times 2^{-4} = +0.111011 \times 2^{-100}$ X: 11011,11.011000000 Y: 11100,00.111011000

浮点数加减运算步骤:

- 1. 对阶 使两个数的阶码相等,小阶向大阶看齐,尾数每右移一位,阶码加1
 - ① 求阶差: [\Delta E] 补=11011+00100=11111, 知\Delta E=-1
 - $X = -0.0101 \times 2^{-100}$ ②对阶: X: 11011,11.011000000 → 11100,11.101100000
- 2. 尾数加减 -Y: 11100,11.000101000 11.101100000 $= (-0.0101 \times 2^{-100}) - (+0.111011 \times 2^{-100})$ + 11.000101000 X-Y: 11100, 10.110001000 $= (-0.0101 - 0.111011) \times 2^{-100}$ 10.110001000
- X-Y: 11100, 10.110001000 \rightarrow 11101,11.011000100 4. 舍入 无舍入
- 5. 判溢出 常阶码, 无溢出, 结果真值为2⁻³×(-0.1001111)₂

王道考研/CSKAOYAN.COM

 $= -1.001111 \times 2^{-100}$

 $= -0.1001111 \times 2^{-011}$

浮点数的加减运算-舍入◆

有的计算机可能会把浮点数的尾数部 分单独拆出去计算(24bit→32bit), 算完 了经过舍入(32bit→24bit)再拼回浮点数

"0"舍"1"入法:类似于十进制数运算中的"四舍五入"法,即在尾 数右移时,被移去的最高数值位为0,则舍去;被移去的最高数值位为1, 则在尾数的末位加1。这样做可能会使尾数又溢出,此时需再做一次右规。

恒置"1"法: 尾数右移时,不论丢掉的最高数值位是"1"还是"0", 都使右移后的尾数末位恒置"1"。这种方法同样有使尾数变大和变小的两 种可能。

浮点数加减运算步骤:

1. 对阶

2. 尾数加减 如:加减结果为11100,10.110001011

3. 规格化

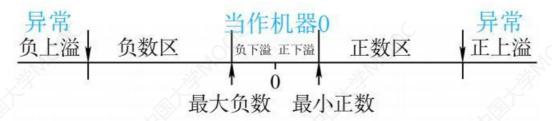
0舍1入: 11100,10.110001011 → 11101,11.0110001011

4. 舍入

恒置1:11100,10.110001011 → 11101,11.011000101 1

→ 11101,11.011000110 1

5. 判溢出 → 11101,11.011000101 1



王道考研/CSKAOYAN.COM

右规时就会面

临舍入的问题

强制类型转换

类型	16位机器	32位机器	64位机器
char	8	8	8
short	16	16	16
int	16	32	32
long	32	32	64
long long	64	64	64
float	16	32	32
double	64	64	64
77		- V'77 15	

 $\mathsf{char} \to \mathsf{int} \to \mathsf{long} \to \mathsf{double}$

float → double

int → float: 可能损失精度 float → int: 可能溢出及损失精度

范围、精度从小到大, 转换过程没有损失

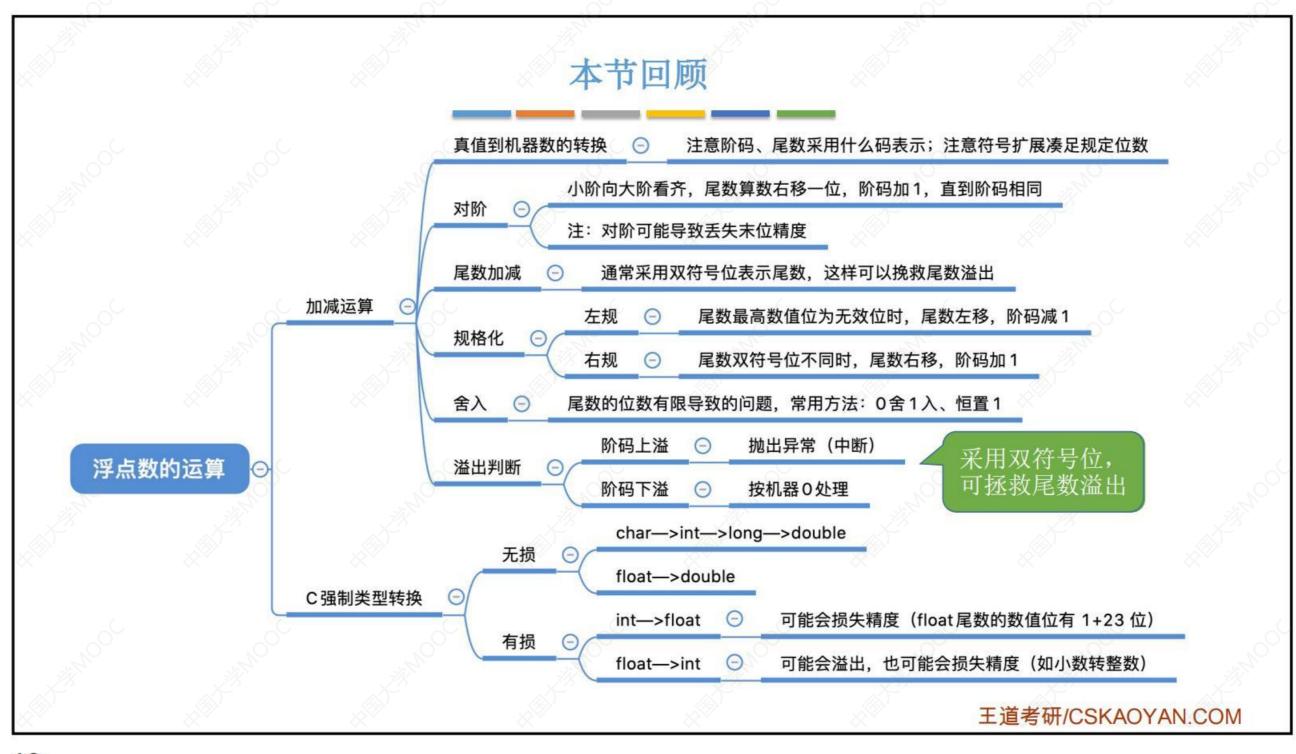
32位

int: 表示整数,范围 - 2^{31} ~ 2^{31} -1,有效数字32位

float: 表示整数及小数,范围 \pm [2⁻¹²⁶ \sim 2¹²⁷ \times (2-2⁻²³)],有效数字23+1=24位

王道考研/CSKAOYAN.COM

9



10







@王道论坛



@王道计算机考研备考 @王道咸鱼老师-计算机考研 @王道楼楼老师-计算机考研



@王道计算机考研

知乎

₩ 微信视频号



@王道计算机考研

@王道计算机考研

@王道在线

11